

Områdesanalys – beslutsunderlag


1. Mål & valt spår

Jag valde att arbeta med spår B. Kunden vill ha hjälp att skapa ett verktyg som snabbt analyserar nya bostadsområden och hjälper till att prioritera de områden som anses vara högrprisområden. Därför vill de skapa en lista baserat på top 20% av priserna för att bättre kunna fördela resurser och göra arbetet mer effektivt. Jag valde detta spår(B) för att göra det så enkelt som möjligt för teamet att snabbt få fram underlag som ska granskas, där de kan sätta igång direkt och inte själva behöva utvärdera något.

2. EDA

Datasetet visade på bra kvalitet, med endast en liten mängd saknad data (1% saknade i antalet sovrum). Genom att titta på inkomst, huspriser samt läge kunde vi få en snabb inblick i sambandet mellan de tre.

Lägre inkomst och lägre avstånd från havet verkar ha ett samband med lägre huspriser. Vi ser även ett övre tak på huspriser, där 4,7% av hushållen hamnar på exakt 500 001\$. Mer exakt data kan eventuellt ge oss ett bättre resultat med våra modeller.



3. Metod

- Jag delar upp datan i ett träningsset och ett testset för att kunna utvärdera modellen på data som den inte tränats på, för att se hur den faktiskt presterar på liknande data.
- Jag delade datan i storlek 80/20 där andelen av klass 1 var samma i båda, jag tränade datan på 80% för att sedan göra en prediktion på testdatan, jag jämförde sedan precision, recall och F1-score.
- Jag testade tre olika modeller för att få med olika typer. LogisticRegression för en enkel linjär modell som är lätt att tolka, DecisionTree för en enkel icke-linjär modell för att jämföra med den mer komplexa RandomForest som är bra vid obalanserad data. Till detta hade jag två baselines som slumpmässiga resultat.
- Jag valde att optimera min modell efter F1, då jag anser att en balans mellan precision och recall gav mig bäst resultat. Hade jag fokuserat på enbart precision så hade resultatet blivit att många högrprisområden missas, medan fokus på recall hade resulterat i många falska positiva, vilket hade ökat arbetsbördan och därmed inte uppfyllt kundens önskemål.

4. Resultat

I figuren nedan ser vi en jämförelse mellan de olika modellerna, de skiljer sig alla åt i de olika mätvärdena. LogisticRegression fångar till exempel flest högrprisområden men har väldigt dålig precision. Sammantaget är RandomForest bäst utav de tre och är den modell jag valde för optimering.

	Accuracy	Precision	Recall	F1
RandomForest	0.9215	0.8862	0.6970	0.7802
DecisionTree	0.8874	0.7252	0.7037	0.7142
LogisticRegression	0.8312	0.5496	0.8656	0.6723

Efter optimering blev resultatet något bättre med ett F1-värde på 79,5% på träningsdatan. Det slutliga resultatet på testdatan såg ut på följande sätt:

	Accuracy	Precision	Recall	F1-score
RandomForest (Optimerad)	0.9130	0.7879	0.7736	0.7807

Vi ser en jämn balans mellan precision och recall, och ett F1 resultat bara strax under träningsdatan, 78,1% mot 79,5%.

5. Rekommendation

Jag rekommenderar RandomForest som modell då den presterade bäst efter min valda metric, F1. Detta då en balans mellan precision och recall passar bäst för kunden. Om vi fokuserar på precision så kommer vi missa för många högprisområden vilket kan vara kostsamt, medan fokus på recall kommer resultera i fler falska positiva och därmed minska effektiviteten för kunden, de kommer granska för många områden som inte matchar deras önskemål.

6. Risker & begränsningar

Om modellen bygger på gammal data kan det ge fel på nya prediktioner när mönster och efterfrågan förändras, för att hålla modellen relevant behöver den tränas om med tiden på ny uppdaterad data. Datans övre gräns på 500 001\$ samt saknade värden är också faktorer som kan påverka resultatet, ju bättre kvalitet desto bättre modell, mönstret bland de 4,7% som hamnar på samma värde kan se något olika ut och därmed förändra hur bra modellen förutspår toppskiktet.

7. Övervakad inlärning

- Övervakad inlärning är när modellen hittar mönster och strukturer i själva datan utan att ha tillgång till några svar.
- Det kan vara relevant för att fånga naturliga mönster eller grupperingar i datan som mina binära modeller inte hittar, för att sedan ta hjälp av dessa som extra features till exempel.
- PCA minskar antalet features och skapar nya variabler där man ser som mest varians i datan. Kluster kan skapa nya grupperingar i datan som inte kopplas till tidigare kända klasser. Detta kan implementeras i modellen för att ge ett bättre resultat.
- Risker med PCA kan vara att det tar bort viktig information som i sig inte är starka men ändå avgörande tillsammans med andra parametrar. Klustring kan vara ett problem om datan har mycket brus eller till exempel som i detta fall, ett tak på huspris.

8. Självreflektion

Jag tycker att jag motiverat mina val väl när det kommer till modell och relevans till uppgiften, samt hur det påverkar vad kunden behöver verktyget till. Svårast var nog hur jag ska hantera ett tak på huspris och hur det påverkar resultatet, hade behövt göra en extra studie på bara detta.

Jag anser att jag uppfyllt kraven på betyget G då jag utfört alla steg som krävs för att få en modell att fungera och göra det den ska. En EDA för dataförståelse och insikter, gjort en split för att kunna träna min modell på ett säkert sätt utan leakage, skapat olika modeller för jämförelse, optimerat en modell efter relevant metric samt gjort en slutlig utvärdering på testdatan och kopplat det till valet av uppgift.